# Smart SH Emergency: KI-gestützte pluviale Überflutungsmodellierung für Einsatzprognosen in Schleswig-Holstein

gds050-01a: Ausgewählte Aspekte des Geoinformationswesens (S) (060884)

Zertifikatstudium GeoDataScience

Des Landesamtes für Vermessung und Geoinformation Schleswig-Holstein und der Mathematisch-Naturwissenschaftlichen Fakultät der Christian-Albrechts-Universität zu Kiel

**Prüfer:**

Dr. rer. nat. Bruno Boemke

M.Eng. Uwe Köster

**Autor:**

Justin Lingg-Laham

15.03.2025

# Abstract

Pluviale Überflutungen zählen weltweit zu den häufigsten und schwerwiegendsten Naturgefahren, welche durch Folgen des Klimawandels sowohl frequenter, als auch intensiver auftreten. Gleichzeitig sind physikalisch basierte hydrologische Modellierungen zwar in der Lage, Überflutungsprozesse detailliert abzubilden, jedoch aufgrund ihrer hohen Rechenkosten nur eingeschränkt für kurzfristige operative Prognosen geeignet. Diese Arbeit untersucht deshalb die Möglichkeiten KI-basierte Überflutungsmodelle zur schnellen Vorhersage von Überflutungsereignissen einzusetzen, im Kontext des Projektes Smart SH Emergency, welches den Aufbau eines Digitalen Geobasis-Zwillings zur Unterstützung von Einsatzleitstellen in Schleswig-Holstein ermöglicht. Dafür wird in dieser Arbeit mit einem U-Net-ähnlichen Convolutional Neural Network (CNN) in der Umgebung JupyterLab gearbeitet, welches aus vier räumlichen Eingabekanälen (Topographie, Niederschlag, Rauigkeit und Infiltration) eine räumlich explizite Wassertiefenkarte prognostiziert. Trainiert wird das KI-Modell mit Trainingsdaten aus hydrodynamischen Simulationen des SIMWE-Modells in GRASS GIS. Ziel ist die Evaluation der Modellleistung sowie die Untersuchung der Übertragbarkeit auf ein zweites Untersuchungsgebiet durch Vergleich mit dem Ergebnis der hydrodynamischen Modellierung. Dazu wird das Modell im urban geprägten Untersuchungsgebiet Lübeck (UG1) trainiert und anschließend ohne erneutes Training auf das rurale Gebiet Barnitz (UG2) übertragen. Die Ergebnisse zeigen, dass das KI-Modell im Trainingskontext eine plausible Annäherung an die Referenzsimulation erreicht. Der Transfer auf UG2 zeigt jedoch einen systematischen Skalierungsfehler der Wassertiefen, welcher zu deutlichen Überschätzungen der Überflutungsfläche und -volumen führt. Durch eine nachgelagerte Quantile-Mapping-Kalibrierung kann dieser Bias effektiv reduziert werden, während jedoch die räumlichen Lageabweichungen bestehen bleiben. Für eine robuste Anwendung im operativen Kontext sind deshalb zusätzliche Kalibrierungs- und Fehlerkorrekturverfahren notwendig, um das KI-Modell effizient zu nutzen und einen Mehrwert für Einsatzleitstellen in ganz Schleswig-Holstein bieten zu können.

# I. Inhaltsverzeichnis


II. Abkürzungsverzeichnis ..... I
III. Abbildungsverzeichnis ..... III
IV. Tabellenverzeichnis ..... IV
1. Einleitung ..... 1
2. KI-basierte Überflutungsprognosen ..... 2
2.1 Motivation: Warum KI? ..... 2
2.2 Stand der Forschung ..... 2
2.3 KI-Modell dieser Arbeit ..... 3
3. Materialien und Methoden ..... 4
3.1 Geographische Einordnung: ..... 4
3.1.1 Untersuchungsgebiet 1 (Urban) ..... 4
3.1.2 Untersuchungsgebiet 2 (Rural) ..... 5
3.2 Vorstellung der Datenerhebung ..... 6
3.3 Vorstellung angewandter Methodik ..... 7
3.3.1 GRASS GIS – Physikalische Hydrologische Referenzmodellierung ..... 7
3.3.2 JupyterLab – KI-Modellierung ..... 8
3.3.3 R – Evaluierungsmetriken ..... 11
4.1 UG1 ..... 14
4.2 UG2 (RAW) ..... 16
4.3 UG2 (CAL) ..... 18
4. Diskussion ..... 20
5.1 Nutzen der Kalibrierung ..... 20
5.2 Grenzen der Kalibrierung und verbleibende Fehler ..... 20
5.3 Datenqualität und Realitätsbezug ..... 20
5.4 Zukunftsausblick ..... 21
5. Fazit ..... 22
Literaturverzeichnis ..... 23

# II. Abkürzungsverzeichnis

| | |
|---|---|
| bDOM | - Digitales Oberflächenmodell |
| CAL | - Kalibrierte Vorhersage |
| CNN | - Convolutional Neural Network |
| DEM | - Digital Elevation Model |
| DGM1 | - Digitales Geländemodell |
| Fn | - False negative |
| Fp | - False positive |
| HAND | - Height Above the Nearest Dreinage |
| IoU | - Intersect over Union |
| KI | - Künstliche Intelligenz |
| LVermGeo | - Landesamt für Vermessung und Geoinformation |
| MAE | - Mean Absolute Error |
| QM | - Quantile Mapping |
| QQ | - Quantile-Quantile-Plot |
| RAW | - Rohe Vorhersage |
| RMSE | - Root Mean Squared Error |
| SIMWE | - Overland flow hydrologic simulation using path sampling method |
| Tn | - True negative |
| Tp | - True positive |
| UG | - Untersuchungsgebiet |

# III. Abbildungsverzeichnis

Abbildung 1: Übersicht des urbanen Untersuchungsgebietes (UG1). Ausschnitt der Hansestadt Lübeck (SH) (Eigene Darstellung) ..... 4
Abbildung 2: Übersicht des ruralen Untersuchungsgebietes (UG2). Ausschnitt des Dorfes Barnitz (SH) (Eigene Darstellung) ..... 5
Abbildung 3: Gelernte Quantil-Mapping-Kalibrationsfunktion Abbildung der rohen KI-Vorhersage (RAW) auf die Referenzskala des GRASS-Modells. Die gestrichelte Linie zeigt die Identität (y=x) als Referenz ohne Korrektur (Eigene Darstellung).10
Abbildung 4: Quantil-Quantil-Plot (QQ) zur Kontrolle der Quantil-Mapping-Kalibration (Abb.3): Dargestellt sind die Quantile der unkalibrierten KI-Ausgabe (RAW) und der kalibrierten Vorhersage (CAL) jeweils gegenüber den Quantilen der Referenzsimulation (GRASS/SIMWE). Die Diagonale zeigt die perfekte Übereinstimmung (Eigene Darstellung). .....10
Abbildung 5: Threshold-Sensitivitätsanalyse: Veränderung der flächenbasierten Kennzahlen (F1-Score und IoU) unter verschiedener Thresholds. Darstellung für RAW und CAL (Eigene Darstellung). .....11
Abbildung 6: GitHub-Repository (Eigene Darstellung). .....13
Abbildung 7: Visueller Vergleich der Wassertiefenfelder für UG1 (KI vs. SIMWE). Oben links: vorausgesagte Wassertiefe des KI-Modells; oben rechts: vorausgesagte Wassertiefe des SIMWE-modells; unten links: Fehlerkarte des KI-Modells (KI-Vorhersage - Referenzoutput); unten rechts: binäre Überflutungskarte zur KI-Evaluierung (Eigene Darstellung). .....14
Abbildung 8: Visueller Vergleich der Wassertiefenfelder für UG2 RAW (KI vs. SIMWE). Oben links: vorausgesagte Wassertiefe des KI-Modells; oben rechts: vorausgesagte Wassertiefe des SIMWE-modells; unten links: Fehlerkarte des KI-Modells (KI-Vorhersage - Referenzoutput); unten rechts: binäre Überflutungskarte zur KI-Evaluierung (Eigene Darstellung). .....16
Abbildung 9: Visueller Vergleich der Wassertiefenfelder für UG2 CALCULATED (KI vs. SIMWE). Oben links: vorausgesagte Wassertiefe des KI-Modells; oben rechts: vorausgesagte Wassertiefe des SIMWE-modells; unten links: Fehlerkarte des KI-Modells (KI-Vorhersage - Referenzoutput); unten rechts: binäre Überflutungskarte zur KI-Evaluierung (Eigene Darstellung). .....18

# IV. Tabellenverzeichnis

Tabelle 1: Auflistung der verwendeten Datensätze zur Analyse der Arbeit (Eigene Darstellung). ..... 6
Tabelle 2: Tabelle der statistischen Evaluierungsmetrik für Untersuchungsgebiet 1 (Eigene Darstellung). ..... 15
Tabelle 3: Tabelle der statistischen Evaluierungsmetrik für Untersuchungsgebiet 2 RAW (Eigene Darstellung). ..... 17
Tabelle 4: Tabelle der statistischen Evaluierungsmetrik für Untersuchungsgebiet 2 CALCULATED (Eigene Darstellung). ..... 19

# 1. Einleitung

Seit 2018 treibt das Land Schleswig-Holstein mit dem Digitalisierungsprogramm gezielt Innovationen in Verwaltung, Forschungseinrichtungen und Universitäten voran. Verwaltet über die Staatskanzlei SH werden dafür jährlich mehrere Million Euro zur Verfügung gestellt. Mit dem aktuellen Digitalisierungsprogramm 4.0 liegen vor allem die Schwerpunkte: Digitale Souveränität, Prozessdigitalisierung & Automation, Einsatz von Künstlicher Intelligenz und Daten im Schwerpunkt (Schleswig-Holstein.de).

In diesem Rahmen liegt auch das Projekt: Smart SH Emergency, des Landesamtes für Vermessung und Geoinformation Schleswig-Holsteins (LVermGeo SH) verortet. Die Hauptaufgabe liegt im Aufbau eines digitalen Geobasis-Zwillings und der fachspezifischen Nutzung desselben zur Unterstützung von Einsatzleitstellen bei Einsatzprognosen. Dabei adressiert das Projekt die wachsenden Herausforderungen in den Einsatzleitstellen von Feuerwehr und Rettungsdiensten, welche unter Ressourcenknappheit (Personal, Fahrzeugen, Verfügbarkeit) leiden. Zeitgleich müssen gesetzte Hilfsfristen eingehalten werden, sodass Schleswig-Holstein flächendeckend innerhalb von 12 Minuten (Rettungsdienst) bzw. 10 Minuten (Feuerwehr) erreichbar bleibt (lfs-sh.de). Um die Anforderungen trotz begrenzter Ressourcen sicherzustellen, ist ein gezielter, datenbasierter Ressourceneinsatz entscheidend. Zwar nutzen die Leitstellen bereits heute verschiedene Hilfsmittel, jedoch erfolgt die Aussendung überwiegend reaktiv auf aktuelle Ereignisse.

An dieser Schnittstelle setzt Smart SH Emergency an: Durch Prozessdigitalisierung und Automation sollen auf Basis Künstlicher Intelligenz (KI) Prognosemodelle entwickelt werden, welche das erwartete Einsatzvolumen und mögliche Einsatzorte vor Eintritt von Notfällen abschätzen können. Dazu werden empirische Einsatzdaten mit zeitlichen Mustern (Jahres-, Wochen-, und Tageszeiten) sowie Einflussfaktoren wie Wetterlagen oder Veranstaltungen mit Hilfe einer KI verknüpft, um Einsatzprognosen „vor der Lage“ treffen zu können.

Die zentrale Komponente dieses Ansatzes sind KI-basierte Überflutungsprognosen. Während hydrologisch und physikalisch basierte Modelle Niederschlagsverteilungen und Überflutungsflächen sehr präzise abbilden können, sind sie aufgrund ihrer komplexen Berechnungen zu langsam, um kurzfristige Wetterprognosen effektiv zu nutzen (HENONIN et al. 2013). Ziel ist es, diesen Vorgang durch KI zu beschleunigen. Dabei wird die KI auf vielen Input und Output-Parametern eines physikalischen Modells trainiert und soll anschließend innerhalb weniger Minute mögliche Überflutungsbereiche auf Basis aktueller Wetterprognosen ableiten.

Als KI-Modell wurde in dieser Arbeit ein U-Net ähnliches Convolutional Neural Network (CNN) eingesetzt, welches auf Basis eines simplen physikalischen Modells (SIMWE aus GRASS GIS) trainiert wurde, um Input-Output-Paare durch synthetischen Niederschlag und Überflutungstiefe zu erstellen. Das Ziel dieser Arbeit ist dabei die Evaluation des KI-Outputs gegenüber des Modelloutputs für zwei verschiedene Untersuchungsgebiete (UG). Dazu erfolgt der Workflow in GRASS-GIS zur hydrologischen Modellierung, der Implementierung des KI-Systems in JupyterLab sowie der abschließenden entwickelten Evaluierungsmetrik in R. Entscheidend ist dabei die Beantwortung der Frage, ob das KI-System auch valide Ergebnisse in ruralen Gebieten erzielt, wenn es zuvor mittels eines urbanen UG trainiert wurde.

# 2. KI-basierte Überflutungsprognosen

Sowohl im globalen als auch regionalen Maßstab gelten die Auswirkungen durch Überschwemmungen zu den gefährlichsten und häufigsten Naturkatastrophen (JONGMAN und VRIJLING, 2008). Dem hinzufügend führt die globale Erwärmung durch den Klimawandel sowohl gegenwärtig als auch zukünftig zu frequenteren und intensiveren Niederschlagsereignissen (IPCC, 2021). Pluviale Überflutungen, ausgelöst durch Starkniederschlagereignisse, stehen dabei im Fokus, welche das vorliegende System überfordern können und so zu hohen Schäden an Infrastruktur, bis hin zu Lebensverlust von betroffenen Lebewesen führen (HOFMANN und SCHÜTTRUMPF 2021, SCHUMACHER, 2017).

## 2.1 Motivation: Warum KI?

Physikalisch basierte hydrologische Modelle liefern zwar detaillierte Ergebnisse, sind aber häufig zu rechenintensiv, um kurzfristige Wetterprognosen in einem operativen Kontext vor Eintritt des Ereignisses zu nutzen (HENONIN et al. 2013; HOFMANN und SCHÜTTRUMPF 2021). Deshalb werden zunehmend Deep-Learning-Modelle genutzt, um klassische Modelle zu ergänzen und zu beschleunigen (BENTIVOGLIO et al. 2022).

## 2.2 Stand der Forschung

Dabei verfolgt Deep-Learning den Ansatz eines Surrogatmodells, bei dem das KI-System aus vielen bereits berechneten Beispielen lernt, um zugrunde liegende Zusammenhänge schnell erzeugen zu können (JIANG et al. 2021). Die Review von Bentivoglio et al. (2022) liefert dabei eine umfassende Einordnung, welche besonders zeigt, dass CNN-basierte Modelle im Flood-Mapping weit verbreitet sind, da räumliche Muster direkt aus Rasterdaten erlernt werden können.

Innerhalb der Modell-Forschung gilt vor allem die U-Net-Struktur als ein etabliertes Grundmodell für räumlich explizite Vorhersagen (LÖWE et al. 2021). U-Net wurde ursprünglich in der Bildverarbeitung für Segmentierungsaufgaben entwickelt und kombiniert einen Encoder, welcher Informationen komprimiert und großräumige Muster lernt, mit einem Decoder, welcher daraus wieder eine Karte in Originalauflösung rekonstruiert (RONNEBERGER et al. 2015). Charakteristisch sind die Skip-Connections, welche die Details aus früheren Stufen enthalten und so den Vergleich räumlicher Strukturen ermöglichen (LÖWE et al. 2021). Überflutungsmodelle profitieren von diesem Aufbau, da sowohl der umfassende Kontext in Form der zu bestimmenden Größen des Einzugsgebietes selbst als auch kleine detailreiche Strukturen wie Kanten oder Senken in der Topographie einen Einfluss nehmen (BENTIVOGLIO et al. 2022). Die pixelbasierte Regression sagt so einen kontinuierlichen Zielwert voraus. Eine beispielhafte Anwendung liefert U-FLOOD, indem eine U-Net-basierte Lösung zur Vorhersage von 2D-Wassertiefen bei urbanen Starkniederschlagereignissen untersucht wird (LÖWE et al. 2021). Dort steht explizit das Ziel im Vordergrund, schnelle Vorhersagen zu ermöglichen, auch für räumliche Situationen, welche außerhalb des Trainings liegen.

Darüber hinaus werden neben U-Net-artigen Regressionsmodellen auch andere Deep-Learning-Ansätze eingesetzt, wie die Generative Adversarial Networks (GANs). Diese bestehen aus zwei Netzen, welche nach dem Gegenspieler-Prinzip trainiert, werden: Ein Generator erzeugt Vorhersagekarten, während ein Diskriminator lernt, realitätsnahe simulierte hydrologische Karten von erzeugten zu unterscheiden. (HOFMANN und SCHÜTTRUMPF 2021).

Beispiel ist hierbei floodGAN, welches als *image-to-image translation* formuliert ist und aus räumlich heterogenen Niederschlagsfeldern 2D-Überflutungskarten erzeugt mit dem expliziten Anspruch auf Echtzeit-Anwendbarkeit (HOFMANN und SCHÜTTRUMPF 2021).

Dabei werden Physikalische Modelle und Deep-Learning nicht als Konkurrenz, sondern als kombinierbare Systeme verstanden (LI et al. 2023). Denn übergreifend bleibt die zentrale Frage, wie gut die Modelle auf neue Gebiete übertragbar sind und wie verlässlich ihre Vorhersagen unter veränderten Bedingungen ausfallen (BENTIVOGLIO et al. 2022).

## 2.3 KI-Modell dieser Arbeit

In dieser Arbeit wird ein U-Net-ähnliches Convolutional Neural Network (CNN) mit zwei Skip-Connections eingesetzt. Das Modell verarbeitet vier räumliche Eingabekanäle (Topographie, Niederschlag, Rauigkeit, Infiltration) und erzeugt als Ausgabe eine 1-kanalige Vorhersage der Wassertiefe. Damit handelt es sich um ein Encoder-Decoder-Modell für bildbasierte, räumlich explizite Vorhersage auf Rasterdaten (LÖWE et al. 2022).

Dabei besteht das Grundprinzip darin, dass das Netzwerk die Eingabedaten im Encoder schrittweise zu abstrakten Merkmalen verdichtet (Downsampling), im Decoder die räumliche Auflösung wieder auf den ursprünglichen Rastermaßstab rekonstruiert (Upsampling) und dabei durch Skip-Connections Informationen aus früheren Stufen integriert. Auf diese Weise können großräumige Informationen bezüglich des Kontextes (Bsp. Allgemeine Abflussstrukturen) mit lokalen Details (Bsp. kleinräumige Topographische Merkmale) kombiniert werden, was entscheidend für die räumliche Verteilung der Wassertiefe ist (RONNEBERGER et al. 2015; LÖWE et al. 2021).

# 3. Materialien und Methoden

Der Methodische Ansatz dieser Arbeit basiert auf dem direkten Vergleich zwischen einem physikalisch basierten Modelloutput und einer KI-basierten vorhersage der Wassertiefe. Im Folgenden werden zur Reproduzierbarkeit die Daten sowie der durchgeführte Arbeitsablauf erläutert.

## 3.1 Geographische Einordnung:

Zur Bewertung der Übertragbarkeit wird der Arbeitsablauf auf zwei Untersuchungsgebiete angewandt. Dabei ist entscheidend, dass das KI-Modell auf das urbane UG1 trainiert wird und anschließend auf das rurale UG2 angewandt wird.

### 3.1.1 Untersuchungsgebiet 1 (Urban)

Das urbane Untersuchungsgebiet 1 (UG1) liegt im Stadtgebiet der Stadt Lübeck, Schleswig-Holstein und repräsentiert die Ausgangslage für pluviale Überflutung in verdichteten Siedlungsräumen (Abb. 1). Aufgrund der räumlich komplexen Strukturen eignen sich urbane Gebiete besonders gut zum Trainieren für KI-basierte Überflutungsprognosen (HOFMANN und SCHÜTTRUMPF 2021). Vor allem heterogener versiegelter Untergrund, mit wechselnder Rauigkeit und Infiltration führt zu kleinräumig differenzierten Wassertiefenmustern im Ergebnis der KI (LÖWE et al. 2021).

Das UG1 fungiert in dieser Arbeit als Grundlage der Trainingsparameter des angewandten KI-Systems. Zur Evaluierung der Übertragbarkeit des KI-Modells wird zudem noch ein zweites Untersuchungsgebiet mit demselben Ausschnitt im ruralen Raum erstellt.

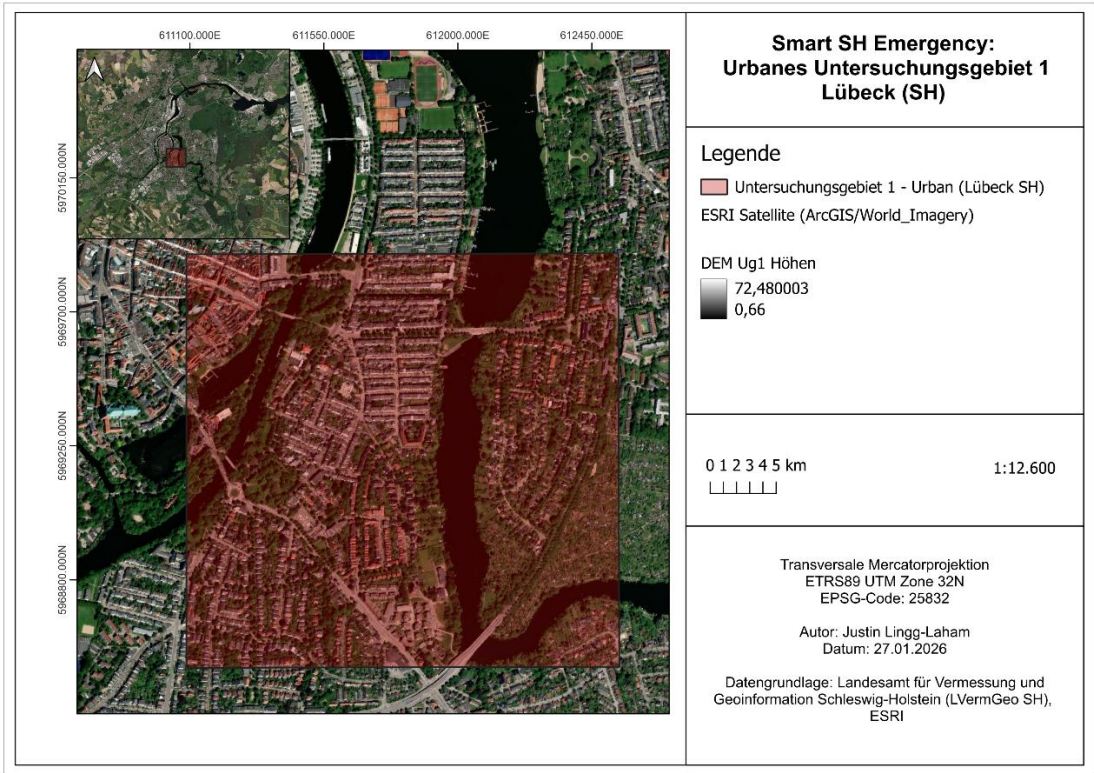


*Abbildung 1: Übersicht des urbanen Untersuchungsgebietes (UG1). Ausschnitt der Hansestadt Lübeck (SH) (Eigene Darstellung)*

### 3.1.2 Untersuchungsgebiet 2 (Rural)

Das rurale Untersuchungsgebiet 2 (UG2) liegt bei Barnitz, Schleswig-Holstein und ist überwiegend durch Landwirtschaftliche Nutzflächen und kleinräumige Vegetations- und Waldanteile geprägt (Abb. 2). Es repräsentiert dabei den durchschnittlichen ruralen Raum Schleswig-Holsteins, mit geringem Gebäudeanteil und durchschnittlichem Relief. Dabei dient die Anwendung des auf UG1 trainierten Modells auf UG2 der Bewertung der Übertragbarkeit.

Im Vergleich zum urbanen Raum unterscheidet sich hier besonders die hydrologische Reaktion und die räumliche Musterung der Überflutung, da Versiegelung eine untergeordnete Rolle spielt, während die Abflussbildung und Wassertiefe stärker an Bodeneigenschaften wie Infiltration und Rauigkeit gekoppelt sind. UG2 eignet sich dabei besonders um zu prüfen, ob das KI-Modell über das urbane Trainingsgebiet hinaus robuste Zusammenhänge gelernt hat oder ob es zu systematischen Abweichungen kommt.

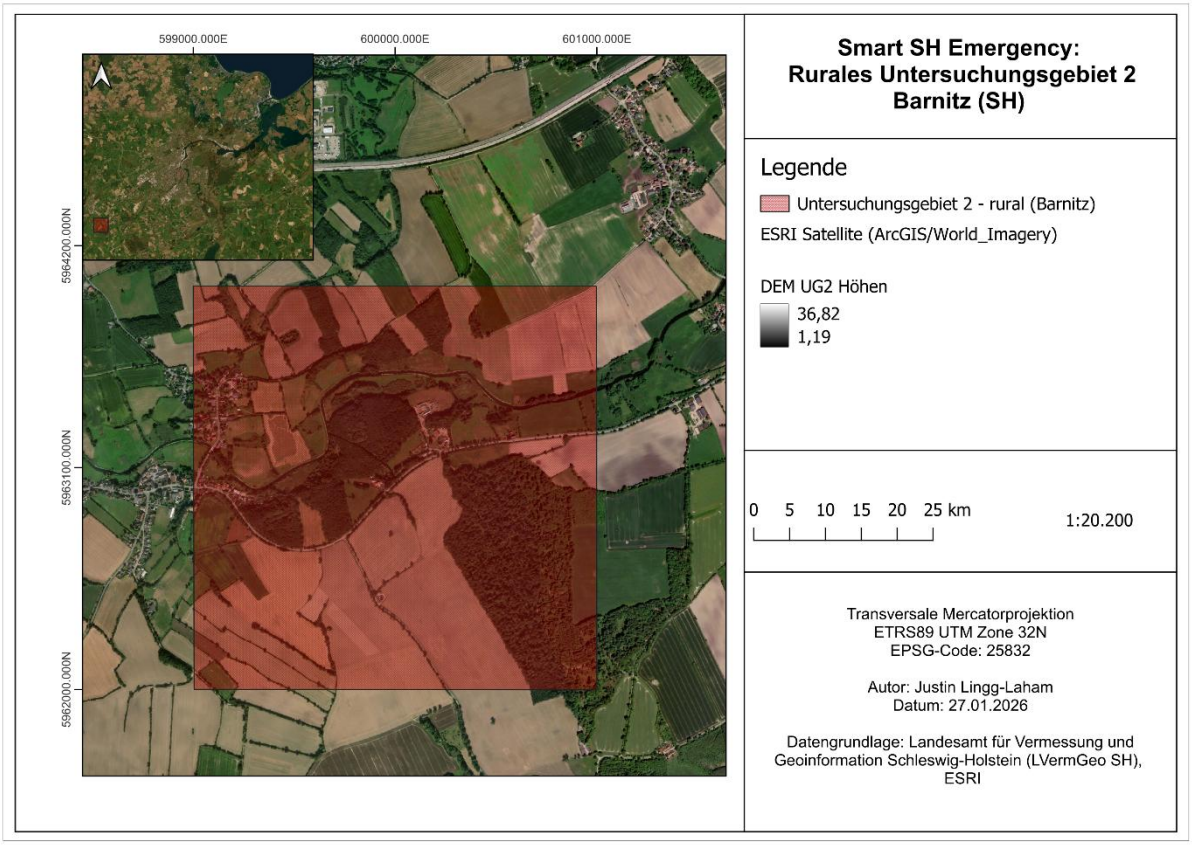


*Abbildung 2: Übersicht des ruralen Untersuchungsgebietes (UG2). Ausschnitt des Dorfes Barnitz (SH) (Eigene Darstellung)*

## 3.2 Vorstellung der Datenerhebung

*Tabelle 1: Auflistung der verwendeten Datensätze zur Analyse der Arbeit (Eigene Darstellung).*

| ***Datensatz*** | ***Typ*** | ***Aufgabe*** | ***Abdeckung*** | ***Format*** | ***Auflösung*** | ***CRS*** | ***Quelle*** |
|---|---|---|---|---|---|---|---|
| *DGM1 ((Digitales Geländemodell)* | Raster | Input (Topographie) | UG1 & UG2 | GeoTIFF | 1 m | EPSG:25832 | Downloadportal SH (LVermGEO) |
| *bDOM (digitales Oberflächenmodell)* | Raster | Input (Gebäudehöhe) | UG1 & UG2 | GeoTIFF | 1 m | EPSG:25832 | Downloadportal SH (LVermGEO) |
| *Gebäudeumringe* | Vektor | Input (Maske) | SH-weit | Shapefile | - | EPSG:25832 | Downloadportal SH (LVermGEO) |
| *DEM (Kombi: DGM1+bDOM via Gebäudeumringe)* | Raster | Input (Topographie) | UG1 & UG2 | GeoTIFF | 1 m | EPSG:25832 | abgeleitet |
| *Rauigkeit (ManningKoeffizient)* | Raster | Input (Rauigkeit) | SH-weit | GeoTIFF | 1 m | EPSG:25832 | ATKIS-DLM |
| *Infiltrationsrate* | Raster | Input (Infiltration) | SH-weit | GeoTIFF | 1 m | EPSG:25832 | ATKIS-DLM |
| *Synthetischer Niederschlag* | Raster | Input (Niederschlag) | UG1 & UG2 | GeoTIFF | UG-Auflösung | EPSG:25832 | IDW-Interpolation |
| *Positiv excess rainfall* | Raster | Input (Effektiver Niederschlag) | UG1 & UG2 | GeoTIFF | UG-Auflösung | EPSG:25832 | abgeleitet |
| *dx/dy (Slope/Aspect)* | Raster | Input (Strömungsrichtung) | UG1 & UG2 | GeoTIFF | UG-Auflösung | EPSG:25832 | r.slope.aspekt |
| *SIMWE (physikalisches Modell)* | Raster | Referenz-Output | UG1 & UG2 | GeoTIFF | UG-Auflösung | EPSG:25832 | GRASS GIS |
| *Patch-Datensatz (X/Y)* | Array | Trainingsdaten (KI) | UG1 | .npy | 64x64 Pixel | - | 01_data_patches_basement Notebook |
| *KI-Output (U-Net)* | Raster/Array | Output (KI) | UG1 & UG2 | GeoTIFF | UG-Auflösung | EPSG:25832 | JupyterLab (U-Net) |
| *Evaluationsmetriken* | Tabelle | Auswertung Modelle | UG1 & UG2 | .csv | - | EPSG:25832 | R |

Tabelle 1 gibt einen Überblick über die in dieser Arbeit verwendeten Datensätze und Layer, einschließlich Datentyp, Quelle und ihrer räumlichen Abdeckung. Die Datengrundlage umfasst (i) topographische Basisdaten zur Ableitung eines hydrologisch sinnvollen Höhenmodells, (ii) flächenhafte Oberflächenparameter (Rauigkeit nach Manning sowie Infiltrationsrate), (iii) synthetisch erzeugte Niederschlagsszenarien als Modellinput sowie (iv) Referenz- und Ergebnisdaten zur späteren Gegenüberstellung von physikalischer Simulation und KI-Vorhersage. Die detaillierte Verarbeitung der Layer (z. B. DEM-Konstruktion, Ableitung von Fließrichtungsgrößen, Modellparametrisierung) wird im anschließenden Methodik-Kapitel beschrieben (Kap. 3.3).

## 3.3 Vorstellung angewandter Methodik

Der methodische Arbeitsablauf dieser Arbeit besteht aus drei aufeinander aufbauenden Arbeitsschritten: (1) der Erzeugung physikalisch basierter Referenz-Modellierung eines simplen Modells in GRASS GIS, (2) der Anwendung eines U-Net-ähnlichen KI-Modells zur schnelleren Wassertiefenprognose sowie (3) der Evaluation der Übereinstimmung zwischen KI-Output und physikalischem Modelloutput. Der vollständige Arbeitsablauf wird im Folgenden beschrieben. Um die Reproduzierbarkeit zu gewährleisten, sind alle Skripte, Dateien und Ausführungsanweisungen zusätzlich im Gitub-Repository hinterlegt (Abb.).

### 3.3.1 GRASS GIS – Physikalische Hydrologische Referenzmodellierung

Zur Erstellung der Referenzdaten wird in dieser Arbeit ein simples physikalisches Model in GRASS GIS eingesetzt. Als hydrologisch-physikalische Grundlage dient das SIMWE-Modell rund um r.sim.water, welches die oberflächliche Abflussbildung und die resultierende räumliche Verteilung der Wassertiefe auf Rasterbasis simuliert. Für das UG1 werden so Zielwerte (Ground Truth) für die KI-Trainingsdaten erzeugt, während für UG2 die gewonnenen Daten als Vergleichsbasis zur Übertragbarkeitsprüfung eben jenes KI-Modells fungieren (HOFIERKA et al. 2015).

Dabei lässt sich der Arbeitsablauf in folgende Schritte gliedern:

1. Ableitung hydrologischer Parameter

Die Grundlage hierfür ist ein Höhenmodell, welches die topographische Streuung realistisch abbildet. Hierzu wird je ein Zusammenschnitt aus vier Kacheln des Downloadportals SH für das Geländemodell (DGM1), dem bDOM und Gebäudeumringen benötigt. Dadurch wird ein realistisches DEM erzeugt, welches Gebäude abbildet, jedoch keine Vegetationshöhen enthält. Die Formel im QGIS-Rasterrechner sieht wie folgt aus:

$$(1)\ if(gebäudelayer = 1, bDOM, DGM1)$$

*(1): Formel zur Erzeugung eines hydrologisch Zusammenhängenden DEMs mit Gebäuden, aber ohne Vegetation (Bruno Boemke, 2025).*

Zudem werden aus dem ALKIS Datenbestand Raster für die Infiltrationsraten sowie Rauigkeitsverhältnisse abgeleitet. Die Input-Layer dx/dy lassen sich in GRASS GIS über das Tool: r.slope.aspect berechnen.

2. Erzeugung der Niederschlagsinputs

Für die Simulation werden verschiedene Niederschlagsszenarien verwendet, welche als flächenhafte Rasterinputs durch eine IDW-Interpolation aus synthetischen Niederschlagspunkten erstellt werden. Diese werden mittels der Infiltrationsraten zu effektiven Niederschlagsrastern verarbeitet (Exakte Anleitung zur Erstellung im GitHub-Repository, Kap. 3.3.3).

3. Vorbereiten des Modellinputs in GRASS GIS

Die Eingangsdatensätze (DEM, Effektiver Niederschlag, Oberflächenparameter (Infiltration, Manning-Koeffizient), dx/dy) werden in GRASS GIS durch eine konsistente Rechenumgebung geführt, um alle Raster in gleiche Ausdehnung, Auflösung und Rasterregion zu bringen.

4. Simulation der Wassertiefe

Anschließend wird die Oberflächenabfluss- und Wassersimulation mit r.sim.water durchgeführt. Das Ergebnis ist ein Raster der Wassertiefe, welches als Referenzprodukt für spätere KI-Abläufe fungiert. Die vollständige, reproduzierbare Schrittfolge inklusive konkreter Funktionsaufrufe und Parameter ist in der begleitenden Workflow-Dokumentation im GitHub hinterlegt.

### 3.3.2 JupyterLab – KI-Modellierung

Auf Basis der physikalischen Simulationen wird ein U-Net-ähnliches Convolutional Neural Network (CNN) als KI-Modell eingesetzt, um Wassertiefen deutlich schneller vorherzusagen. Das Modell ist als Encoder-Decoder-Architektur implementiert und nutzt zwei Skip-Connections, um beim Upsampling neben dem großen räumlichen Kontext auch lokale Details zu erhalten (LÖWE et al. 2022). Damit wird in dieser Arbeit eine Raster-zu-Raster-Abbildung erlernt, da mehrere Eingabelayer auf ein Wassertiefenraster abgebildet werden.

Dabei verarbeitet das verwendete Netzwerk vier Eingabekanäle pro Patch mit einer Größe von 64x64 Pixeln. Diese Kanäle repräsentieren die zentralen Einflussgrößen der Überflutungsdynamik:

1. DEM (Streuung von Abflusswegen und Senkenbildung)
2. Niederschlag (räumliche Verteilung und Intensität des Inputs)
3. Rauigkeit (Abflusshemmung durch Oberflächeneigenschaften)
4. Infiltration (Versickerung der Überflutungsmasse)

Im Encoder werden die Eingabedaten über Faltungsoperationen (Conv2D) zusammen mit Batch-Normalisierung und Max-Pooling auf niedrigere Auflösungsstufen verdichtet (64 zu 32 zu 16 Pixeln) (Conv2d, 2026). Parallel steigt die Anzahl der Feature-Kanäle (32 zu 64 zu 128), wodurch das Modell zunehmend abstrakte Muster der Abfluss- und Überflutungsentstehung repräsentieren kann (BADRINARAYANAN et al. 2017).

Im Decoder wird danach die räumliche Auflösung über Upsampling wieder auf 64x64 Pixel rekonstruiert. Die U-Net-Charakteristik entsteht dabei durch die Skip-Connections (Concatenate), welche Merkmale aus dem Encoder direkt in den Decoder einspeisen. Dadurch bleiben feine topographische Strukturen besser erhalten, ohne Sie zu glätten (BADRINARAYANAN et al. 2017).

Die Ausgabe erfolgt über eine finale 1-Kanal-Faltung, welche dafür sorgt, dass jeder Pixel eine kontinuierliche Wassertiefe vorhersagt. Das Modell ist damit ein dichtes Regressionsmodell, welches metrische Werte pro Rasterzelle liefert (LÖWE et al. 2022; BADRINARAYANAN et al. 2017).

Trainiert wird das KI-Modell auf UG1, mit Trainingsdaten aus den physikalischen SIMWE-Simulationen und anschließend ohne erneutes Training auf UG2 angewandt.

Bei der Übertragung eines auf einem Untersuchungsgebiet trainierten Modells auf ein anderes Gebiet können sich die statistischen Eigenschaften der Eingangsdaten und Zielgröße unterscheiden. Diese Unterschiede führen dazu, dass die KI-Ausgabe zwar plausible räumliche Muster liefert, die Skalierung bzw. Werteverteilung jedoch nicht optimal zur Referenzskala passt (GHAZI AL-RAWAS et al. 2025). Um diese Skalierungsdifferenz ohne erneutes Modelltraining zu erreichen, wird in dieser Arbeit zusätzlich eine nachgelagerte Kalibrierung der KI-Wassertiefen angewandt (CAL). Dabei wird als Kalibrierungsmethode Quantil Mapping (QM) verwendet, bei der eine monotone Abbildungsfunktion erlernt wird, welche die Verteilung der Rohvorhersagen (RAW) auf die Verteilung der SIMWE-Werte abbildet (ANDRADE et al. 2024; BYUN und HAMLET 2024). Dabei wird über die Zuordnung gleicher Quantile ein vorhergesagter Wert zunächst in sein Quantil innerhalb der RAW-Verteilung übersetzt und anschließend auf den entsprechenden Wert der Referenzverteilung (SIMWE) zurückgeführt. Dadurch bleibt die Vorhersage erhalten, während die Werte auf der Referenzskala transformiert werden (BYUN und HAMLET 2024).

Die angewandte Quantil-Mapping-Kalibrierung wird in Abbildung 3 durch die gelernte Abbildungsfunktion aufgezeigt. Zudem zeigt Abbildung 4 ergänzend einen Quantil-Quantil-Plot (QQ) als Plausibilitätscheck der verteilungsbasierten Anpassung. Die Kalibrierung wird in der Evaluation explizit berücksichtigt, indem die Auswertungen sowohl für RAW als auch für CAL für UG2 durchgeführt werden.

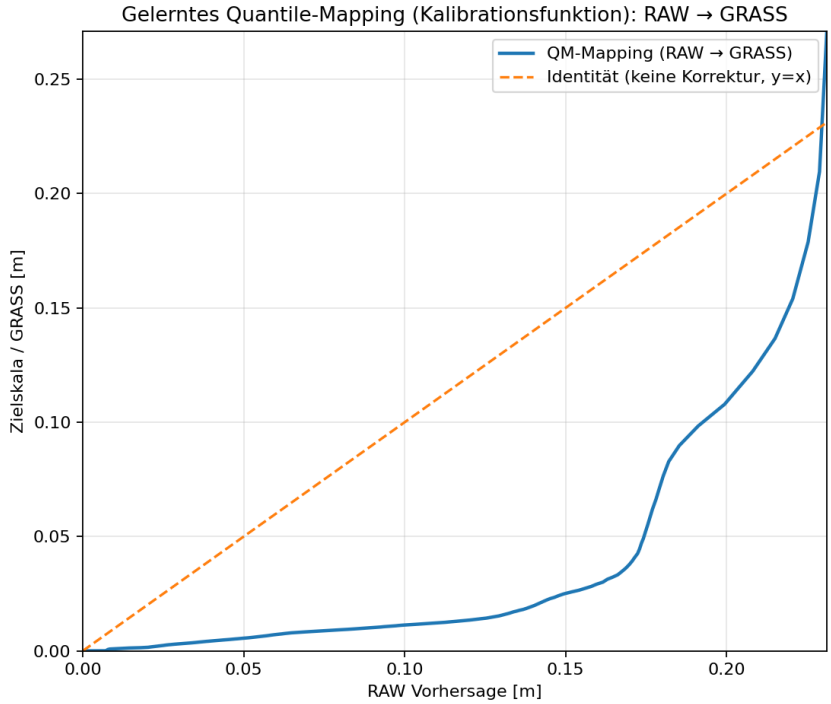


*Abbildung 3: Gelernte Quantil-Mapping-Kalibrierfunktion Abbildung der rohen KI-Vorhersage (RAW) auf die Referenzskala des GRASS-Modells. Die gestrichelte Linie zeigt die Identität (y=x) als Referenz ohne Korrektur (Eigene Darstellung).*

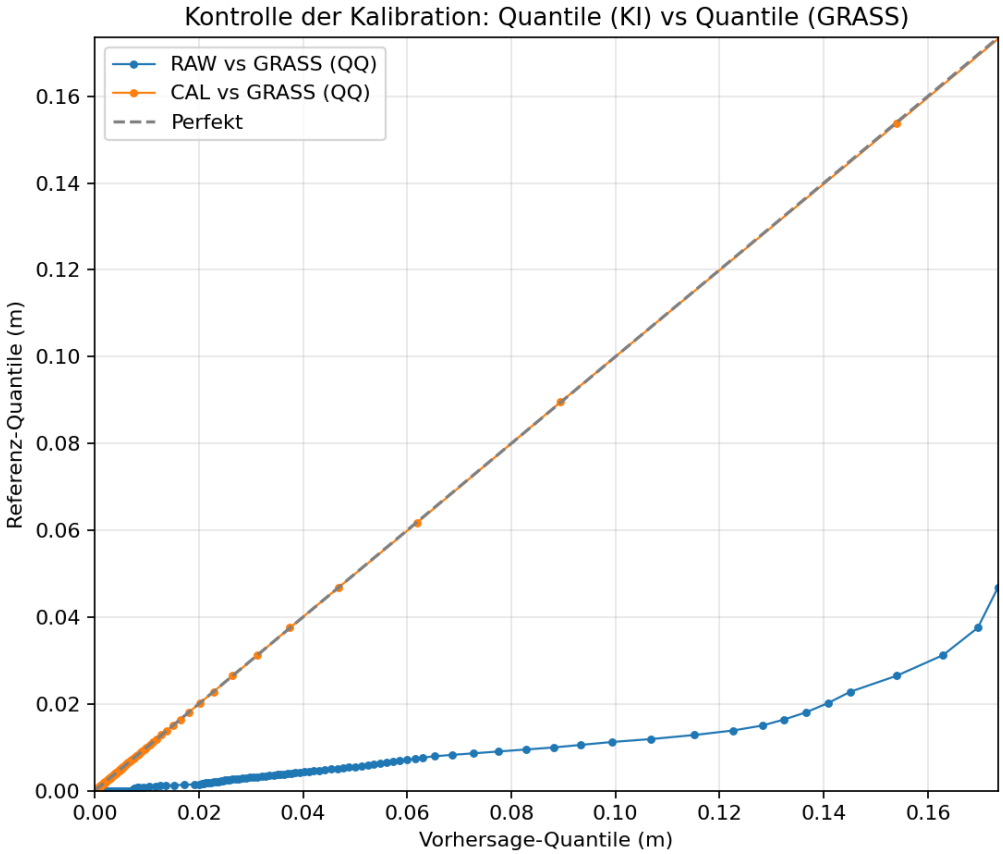


*Abbildung 4: Quantil-Quantil-Plot (QQ) zur Kontrolle der Quantil-Mapping-Kalibration (Abb.3): Dargestellt sind die Quantile der unkalibrierten KI-Ausgabe (RAW) und der kalibrierten Vorhersage (CAL) jeweils gegenüber den Quantilen der Referenzsimulation (GRASS/SIMWE). Die Diagonale in grau gestrichelt zeigt die perfekte Übereinstimmung (Eigene Darstellung).*

### 3.3.3 R – Evaluierungsmetriken

Die Bewertung der Modelle zielt darauf ab, die Übereinstimmung zwischen KI-Output und SIMWE-Output zu beschreiben. Die Auswertung erfolgt dabei getrennt für UG1 und UG2, um neben der reinen Modellgüte auch die Übertragbarkeit zu analysieren. Grundlage sind dabei die rastergleichen Datensätze (identische Ausdehnung, Auflösung und Zellzuordnung), sodass ein pixelweiser Vergleich möglich ist. Zudem werden für UG2 zwei Varianten betrachtet: eine unkalibrierte Vorhersage (RAW) und eine zusätzlich aufbereitete und kalibrierte Variante (CAL) um mögliche Verbesserungen der Übereinstimmung zu untersuchen.

Die räumliche Überflutungsausdehnung wird dabei zusätzlich über eine binäre Threshold-Maske beschrieben, da die Wassertiefenfelder typischerweise große Anteile an nicht überfluteter Zellen (Wassertiefe = 0) enthalten. Die Klassierung sieht wie folgt aus:

- Überflutet: Wassertiefe ≥ Threshold
- Nicht überflutet: Wassertiefe < Threshold

Als Referenzfläche für tabellarische Kennzahlen wird in dieser Arbeit ein Threshold von 0,01 Metern verwendet, also alles ab 1 cm gilt als überflutet. Die Entscheidung basiert auf einer durchgeführten Threshold-Sensitivitätsanalyse, um zu prüfen, wie robust die Ergebnisse gegenüber der Wahl des Schwellenwertes sind (Abb. 5, LÖWE et al. 2021).

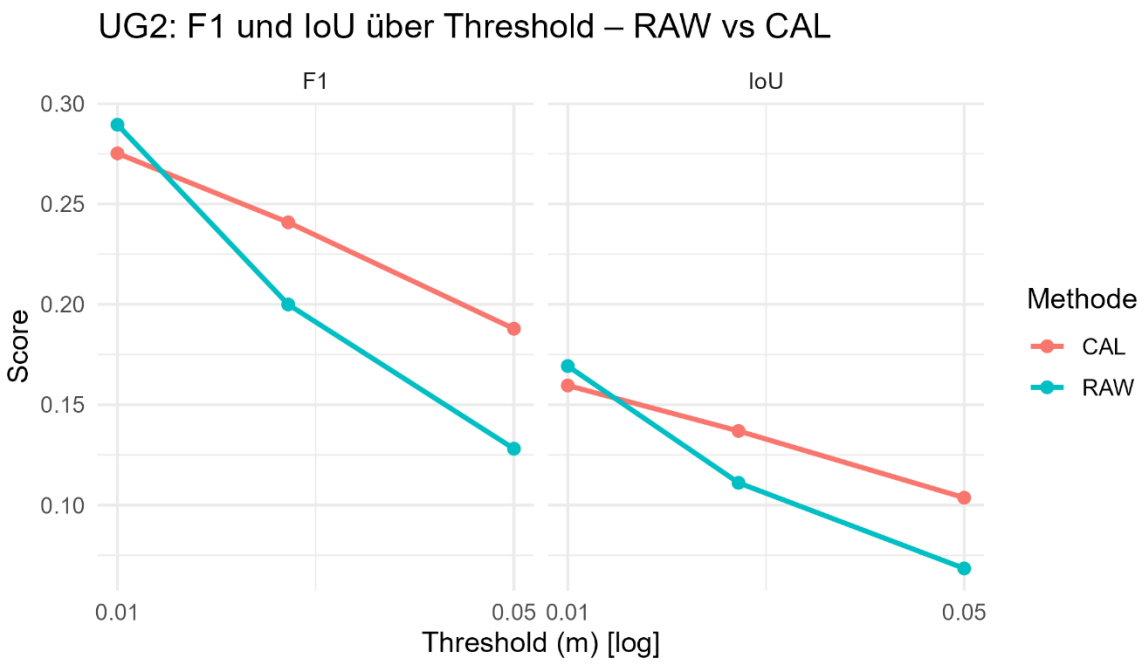


*Abbildung 5: Threshold-Sensitivitätsanalyse: Veränderung der flächenbasierten Kennzahlen (F1-Score und IoU) unter verschiedener Thresholds. Darstellung für RAW und CAL (Eigene Darstellung).*

Auf Basis der binären Überflutungsmaske wird im Anschluss eine Konfusionsmatrix gebildet:

- TP (True Positive): KI und SIMWE sagen Überflutung voraus (Korrekt Nass)
- TN (True Negative): KI und SIMWE sagen keine Überflutung aus (Korrekt trocken)
- FP (False Positive): KI sagt Überflutung, SIMWE nicht (KI Zu Nass)
- FN (False Negative): SIMWE sagt Überflutung, KI nicht (KI zu trocken)

Aus der Klassifizierung können direkt flächenbezogene Größen berechnet werden, da die Zellfläche im Raster bekannt ist (bei 1 $m^2$-Zellen entspricht 1 Pixel = 1 $m^2$). Zudem werden zusätzlich relative Kennwerte ausgewiesen, um die Interpretierbarkeit zu erleichtern, Bsp. KI-Überflutungsfläche relativ zur SIMWE Fläche (FP, FN)

Als zusammenfassende Gütemaße für die Übereinstimmung der Überflutungsflächen werden zwei statistische Haupt-Evaluationsmetriken verwendet:

- F1-Score (Balance Score) als Maß für die Vorhersagequalität aus dem harmonischen Mittel der Präzision und Trefferquote (Scikit-learn 2025)

$$(2)\ F1 = \frac{2 \times TP}{2 \times TP + FP + FN}$$

(3)

*(2) Formel zur Bestimmung des F1-Scores: Bewertung der binären Vorhersagegüte durch Kombination aus Präzision und Recall, basierend auf True Positives (TP), False Positives (FP) und False Negatives (FN).*

- Intersection over Union (IoU-Ähnlichkeitsmaß) zur Zählung der Überlappung zwischen zwei vorhergesagten Größen (oder einer Vorhersage und einer Wahrheit) (v7labs)

$$(3)\ IoU = \frac{TP}{TP + FP + FN}$$

*(3) Formel zur Bestimmung des Ähnlichkeitsmaßes IoU: Quantifizierung der Flächen-/Pixelüberlappung zwischen Vorhersage und Wahrheit. Definiert als das Verhältnis von Schnittmenge zu Vereinigungsmenge.*

Zusätzlich werden verschiedene Fehlermaße für die Wassertiefe als kontinuierliche Zielgröße ermittelt, über klassische Regressionsmetriken:

- Mean Absolute Error (MAE): mittlere absolute Abweichung der Wassertiefe (linearer Durchschnitt der absoluten Fehler)
- Root Mean Squared Error (RMSE): Durchschnittliche Abweichung der vorhergesagten Wassertiefe (gibt Fehlern durch Quadrierung eine stärkere Gewichtung und ist so empfindlicher für Ausreißer)
- Bias: Systematische Verzerrung, also Über- oder Unterschätzung

Diese Kennzahlen werden pro Ereignis berechnet und erlauben quantitative Aussagen, wie weit das KI-Modell in Metern vom physikalischen Modell abweicht. Ergänzend dazu werden zudem Bilanzgrößen zu Flächen- und Volumengröße hinzugezogen:

- Überflutete Fläche in $m^2$ (KI vs. SIMWE)
- Überflutungsvolumen in $m^3$ (KI vs. SIMWE)

Das Überflutungsvolumen wird dabei aus der Summe der Wassertiefe über die Rasterzelle unter Berücksichtigung der Zellfläche berechnet.

Der genaue Ablauf zur Reproduzierbarkeit der Analyse ist unter folgendem GitHub-Repository abzusehen, ebenso wie die verwendeten Daten und Anleitung zur Datenbeschaffung:

https://github.com/geojussl/Smart-SH-Emergency-AI-based-pluvial-flood-modelling-for-operational-forecasts-in-Schleswig-Holstein.git

*Abbildung 6: GitHub-Repository (Eigene Darstellung).*

# Ergebnisse

Die Ergebnisse der Arbeit werden in drei Teile gegliedert: (i) die Ergebnisse des Untersuchungsgebietes 1 zur Bewertung der grundsätzlichen Funktionsfähigkeit des KI-Modells, (ii) die Ergebnisse des Untersuchungsgebietes 2 (RAW) zur Bewertung der Übertragbarkeit des KI-Modells und (iii) die Ergebnisse des Untersuchungsgebietes 2 (CAL) zum Aufzeigen der Wichtigkeit der Modellanpassung durch Kalibrierung.

## 4.1 UG1

Die Ergebnisse der vorhergesagten Wassertiefen des KI-Modells für UG1 werden rasterweise dem physikalischen Referenzmodell (SIMWE) gegenübergestellt (Abb. 6). Erkennbar werden vor allem die räumlichen Muster, welche anzeigen, dass das KI-Modell grundlegend die wesentlichen Überflutungsbereiche an ähnlichen Stellen wie die SIMWE-Referenzmodellierung lokalisiert. Gleichzeitig fällt im visuellen Vergleich auf, dass das SIMWE-Modell deutlich kleinräumiger und texturierter, bzw. detailreicher ist, während die KI-Ausgabe glatt und oberflächlich wirkt (Abb. 6).

Diese Glättung ist auch in der Fehlerkarte erkennbar, denn größere Abweichungen treten weniger Flächendeckend auf, sondern konzentrieren sich auf einige Hotspots entlang der Hauptüberflutungszone und in Bereichen mit starkem räumlichem Kontrast, wie Übergangsbereichen oder linearen Strukturen (Abb. 6).

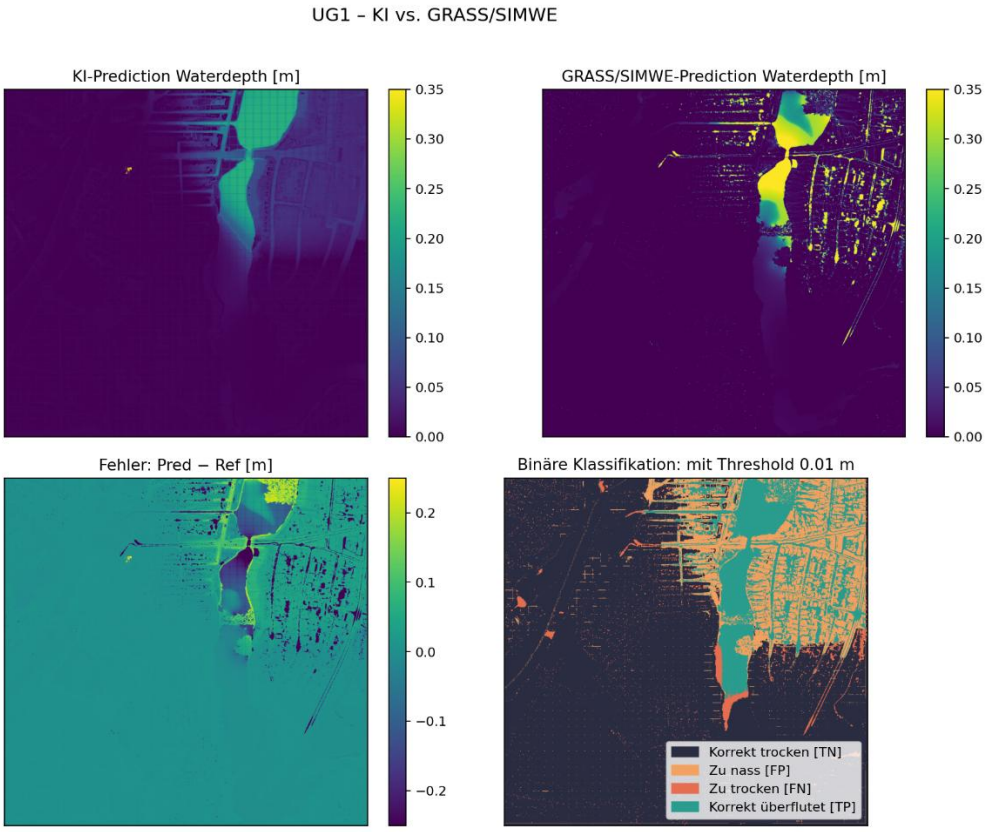


*Abbildung 7: Visueller Vergleich der Wassertiefenfelder für UG1 (KI vs. SIMWE). Oben links: vorausgesagte Wassertiefe des KI-Modells; oben rechts: vorausgesagte Wassertiefe des SIMWE-modells; unten links: Fehlerkarte des KI-Modells (KI-Vorhersage - Referenzoutput); unten rechts: binäre Überflutungskarte zur KI-Evaluierung (Eigene Darstellung).*

Bestätigt wird das Bild durch die statistischen Kennzahlen der KI-Modellierung (Tab. 2):

- MAE = 0.021 m (ca. 2,1 cm): Im Mittel liegt die KI-Wassertiefe nah an der Referenz.
- RMSE = 0.117 m (ca. 11,7 cm): Der höhere RMSE zeigt, dass es neben kleinen Abweichungen wenige, aber starke Fehler gibt (lokale Hotspots).
- Bias = 0,000 m: Im Mittel liegt keine systematische Über- oder Unterschätzung der Wassertiefe

Die flächenhafte Überflutungsübereinstimmung ergibt (Tab. 2):

- F1-Score = 0.605 und IoU = 0.434: Dies entspricht einer mittel- bis guten Überlappung der Überflutungsfläche. Die KI trifft einen Großteil der überfluteten Bereiche korrekt, ist aber nicht deckungsgleich mit dem SIMWE-Modell.

Bei der Größenordnung der vorhergesagten Ausdehnung ist jedoch ein deutlicher Unterschied erkennbar (Tab. 2):

- Überflutungsfläche KI = 491.736 $m^2$ gegen SIMWE = 277.846 $m^2$: Mathematisch ist dies ein Anstieg von ca. +77%. Deutlich erkennbar in der binären Karte, da viele false Positives“ (FP) auftreten, weshalb unser KI-Modell häufig „zu nass“ voraussagt (Abb. 6).
- Volumen KI = 36.376 $m^3$ gegen SIMWE = 38.721 $m^3$: Im Gegensatz zur Fläche liegt die KI bei Volumen nur um etwa 6% niedriger als das physikalische Modell.

*Tabelle 2: Tabelle der statistischen Evaluierungsmetrik für Untersuchungsgebiet 1 (Eigene Darstellung).*

| UG1 – Statistik (Threshold 0.01 m) | | | | | | | | | | | |
|---|---|---|---|---|---|---|---|---|---|---|---|
| Gebiet | Methode | Threshold [m] | MAE [m] | RMSE [m] | Bias [m] | Balance Score (F1) | Ähnlichkeitsmaß (IoU) | Fläche KI [$m^2$] | Fläche GRASS [$m^2$] | Vol KI [$m^3$] | Vol GRASS [$m^3$] |
| UG1_1_80 | RAW | 0.010 | 0.021 | 0.117 | 0.000 | 0.605 | 0.434 | 491 736 | 277 846 | 36 376 | 38 721 |

Obwohl die KI eine deutlich größere Überflutungsfläche ausweist, bleibt das Gesamtvolumen ähnlich. Das spricht dafür, dass das KI-Modell Wasser tendenziell breiter bzw. flächiger verteilt, dabei jedoch an vielen Stellen geringere Tiefen vorhersagt. Dieses Muster passt zur visuell „glatteren“ KI-Karte und zum Auftreten vieler FP-Erzeugnisse der binären Auswertung (Abb. 6).

Das KI-Modell erzeugt für UG1 im Trainingskontext eine solide Basisleistung, mit geringen mittleren Tiefenfehlern, räumlich plausibler Überlappung, jedoch zu flächenhafter Ausdehnung von Überflutungen bei einer Gesamtwassermenge, welche nahe an der Referenz bleibt.

## 4.2 UG2 (RAW)

Im ruralen Untersuchungsgebiet 2 zeigt der visuelle Vergleich zwischen KI-Modell und SIMWE-Modell (Abb. 7) eine deutlich geringere Übereinstimmung als im urbanen Trainingsgebiet (UG1). Während das SIMWE-Modell die Überflutung entlang klarer, natürlicher Abflussstrukturen und senken konzentriert (Abb. 7 oben rechts), erzeugt die KI-Vorhersage (RAW) eine großflächige, zusammenhängende Wasserfläche (Abb. 7 oben links), welche sowohl räumlich als auch in der Intensität über die Referenzausgabe hinaus geht. Die Fehlerkarte verdeutlicht dies, mit großen Bereichen positiver Differenz, in welcher das KI-Modell über dem Referenzniveau liegt (Abb. 7).

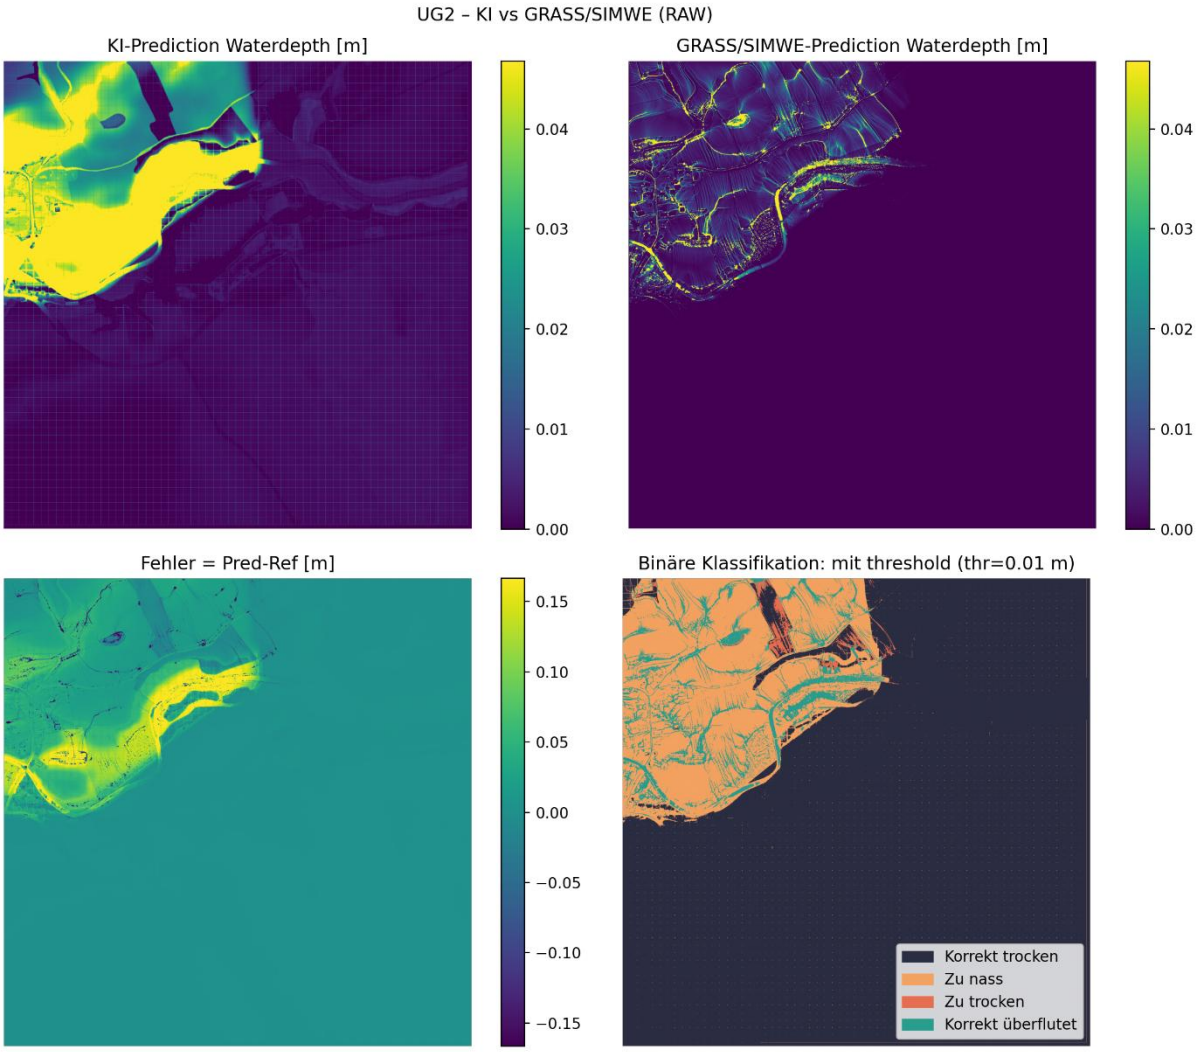


*Abbildung 8: Visueller Vergleich der Wassertiefenfelder für UG2 RAW (KI vs. SIMWE). Oben links: vorausgesagte Wassertiefe des KI-Modells; oben rechts: vorausgesagte Wassertiefe des SIMWE-modells; unten links: Fehlerkarte des KI-Modells (KI-Vorhersage - Referenzoutput); unten rechts: binäre Überflutungskarte zur KI-Evaluierung (Eigene Darstellung).*

Gestützt wird die visuelle Beobachtung durch die statistischen Kennzahlen der Modellierung (Tab. 3), insbesondere durch das Bias, welches für das UG2 bei +0.012 m liegt, was eine systematische Überschätzung der ausgegebenen KI-Wassertiefe verdeutlicht. Für die Interpretation ist dieser positive Offset zentral, da er verdeutlicht, dass die KI nicht nur punktuell abweicht, sondern das gesamte Überflutungssignal durch einen systematischen Fehler verschoben, bzw. angehoben wird (Tab. 3).

Das Muster spiegelt sich vor allem in den flächen- und volumenbezogenen Ergebnissen wider:

- Überflutungsfläche KI = 833.839 $m^2$ gegen SIMWE = 180.226 $m^2$: Mathematisch ist das KI-Modell 4,6-fach so hoch.
- Volumen KI = 50.841 $m^3$ gegen SIMWE = 7.823 $m^3$: Ein ca. 6,5-facher Anstieg.

Die binäre Karte zeigt dementsprechend eine Dominanz an „zu nassen“ Pixeln an (Abb. 7 unten rechts) und auch die Übereinstimmungsmaße zeigen mit F1 = 0.308 und IoU = 0.182 eine geringe räumliche Überlappung zwischen KI-Modell und referenzierter Überflutungsfläche auf (Tab. 3).

*Tabelle 3: Tabelle der statistischen Evaluierungsmetrik für Untersuchungsgebiet 2 RAW (Eigene Darstellung).*

| UG2 – Statistik (RAW, Threshold 0.01 m) | | | | | | | | | | | |
|---|---|---|---|---|---|---|---|---|---|---|---|
| Gebiet | Methode | Threshold [m] | MAE [m] | RMSE [m] | Bias [m] | Balance Score (F1) | Ähnlichkeitsmaß (IoU) | Fläche KI [m²] | Fläche GRASS [m²] | Vol KI [m³] | Vol GRASS [m³] |
| UG2_1_80 | RAW | 0.010 | 0.013 | 0.034 | 0.012 | 0.308 | 0.182 | 833 839 | 180 226 | 50 841 | 7 823 |

Auffällig ist dabei, dass die reinen Tiefenfehlermaße zunächst moderat wirken, mit MAE = 0.013 m und RMSE = 0.034 (Tab. 3). In Kombination mit dem klar positiven Bias wird jedoch das Hauptproblem der systematischen Skalierungsverschiebung deutlich. Das KI-Modell liegt insgesamt zu hoch, wodurch sich die Ausdehnung und Wassermenge überproportional erhöhen.

Abgeleitet aus den Ergebnissen des UG2 (RAWs) ist der nächste Schritt die Adressierung des systematischen Fehlers (Bias) durch eine Kalibrierung des KI-Modells durch die eingangs erwähnte Quantile-Mapping-Kalibrierung (Kapitel 3.3.2) um die Werteverteilung der KI-Wassertiefen besser an die Referenzskala anzupassen (ENAYATI et al. 2020).

## 4.3 UG2 (CAL)

Nach der Quantile-Mapping-Kalibrierung zeigt der visuelle Vergleich in Abbildung 8 eine deutlich veränderte Charakteristik der KI-Ausgabe. Die kalibrierte Vorhersage der KI-Wassertiefe (Abb. 8 oben links) konzentriert sich wesentlich stärker auf die Bereiche, in denen auch das SIMWE-Modell (Abb. 8 oben rechts) Überflutung aufweist. Die zuvor großflächige Wasserfläche der UG2 RAW-Vorhersage wird stark zurückgenommen.

Dementsprechend fällt die Fehlerkarte (Abb. 8 unten links) deutlich unausgeprägter aus. Die Farbskala reicht hier nur noch bis etwa ±0,06 m, während in der RAW-Variante deutlich größere Abweichungen sichtbar waren. Das spricht dafür, dass die Kalibrierung vor allem die systematische Überschätzung der Wassertiefen reduziert.

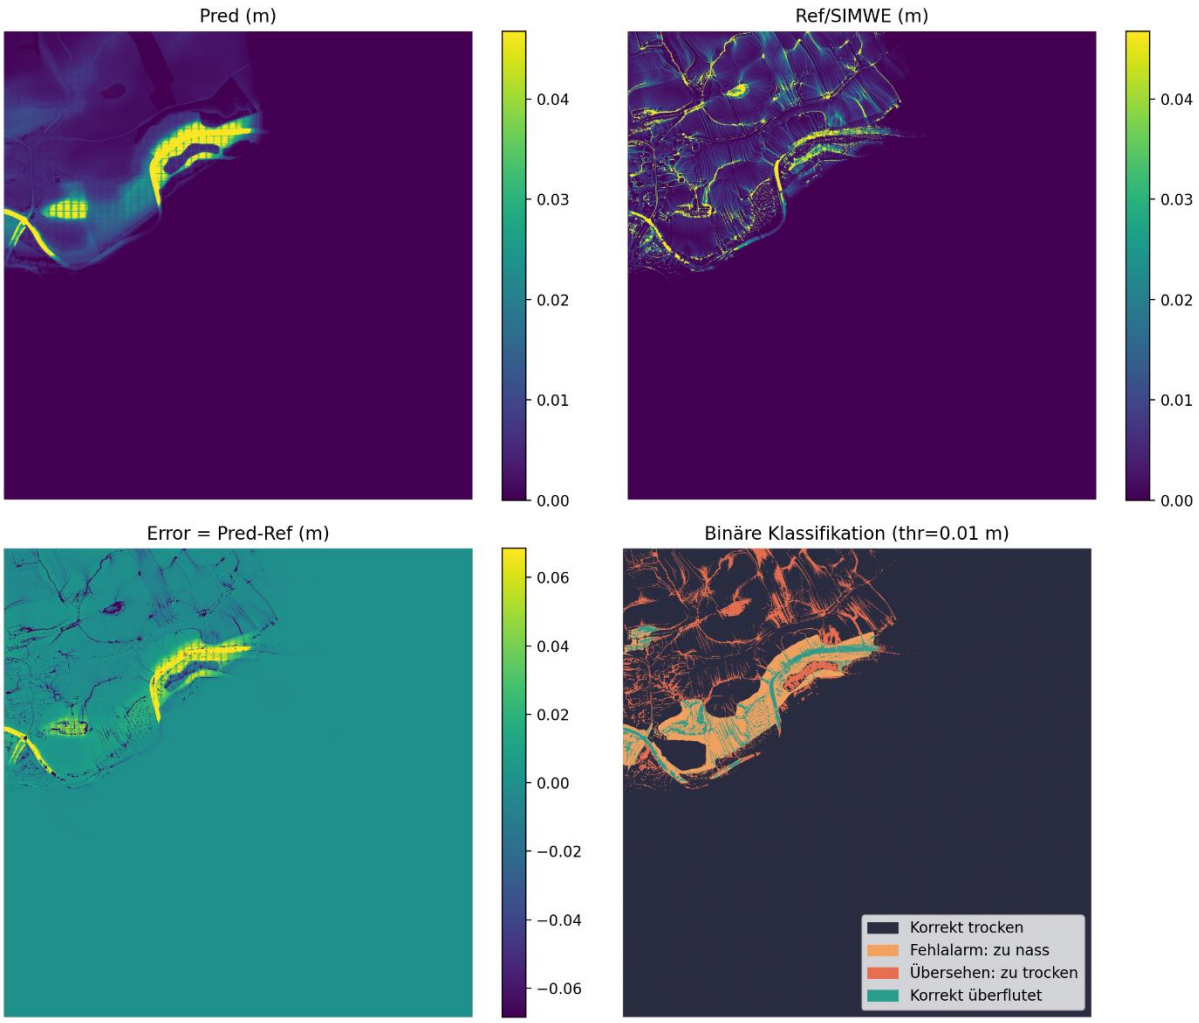


*Abbildung 9: Visueller Vergleich der Wassertiefenfelder für UG2 CALCULATED (KI vs. SIMWE). Oben links: vorausgesagte Wassertiefe des KI-Modells; oben rechts: vorausgesagte Wassertiefe des SIMWE-modells; unten links: Fehlerkarte des KI-Modells (KI-Vorhersage - Referenzoutput); unten rechts: binäre Überflutungskarte zur KI-Evaluierung (Eigene Darstellung).*

Diese Veränderung ist auch deutlich in den statistischen Kennzahlen sichtbar (Tab. 4)

- MAE = 0.003 m (ca. 0,3 cm): Die mittlere Abweichung der Wassertiefe sinkt deutlich und liegt nun im Millimeterbereich.
- RMSE = 0.022 m (ca. 2,2 cm): Auch der RMSE reduziert sich gegenüber RAW, was auf eine generelle Abschwächung starker Abweichungen hinweist.
- Bias = 0,000 m: Das zuvor positive Bias (systematisch „zu nass“) ist nach der Kalibrierung ausgebessert. Er gibt an, dass die QM-Kalibrierung des Modells perfekt funktioniert hat.

Besonders deutlich ist der Effekt bei der überfluteten Fläche zu erkennen:

- Überflutungsfläche KI = 180.220 $m^2$ gegen SIMWE = 180.226 $m^2$: Damit stimmt die Überflutungsausdehnung numerisch fast exakt überein, mit einer Differenz von wenigen Quadratmetern.
- Volumen KI = 8.074 $m^3$ gegen SIMWE = 7.832 $m^3$: Auch das Volumen liegt nun sehr nahe an der SIMWE-Modellierung.

In der binären Klassifizierung (Abb. 8 unten rechts) lässt sich die Veränderung deutlich sehen, da die zuvor dominierenden False Positives (FP: „zu nass“) deutlich reduziert werden. Gleichzeitig zeigt die Karte aber auch, dass die Kalibrierung die Überflutungsfläche zwar in Punkto Größenordnung und in der Skalierung anpassen kann, die zugrunde liegenden räumlichen Muster jedoch nicht verändert werden.

Das erklärt, wieso die flächenhaften Überflutungsübereinstimmungen nicht automatisch ansteigen (Tab. 4):

- F1-Score = 0.284 und IoU = 0.165: Diese liegen trotz verbesserter Skalierung weiterhin im niedrigen Bereich.

*Tabelle 4: Tabelle der statistischen Evaluierungsmetrik für Untersuchungsgebiet 2 CALCULATED (Eigene Darstellung).*

| UG2 – Statistik (Calculated, Threshold 0.01 m) | | | | | | | | | | | |
|---|---|---|---|---|---|---|---|---|---|---|---|
| Gebiet | Methode | Threshold [m] | MAE [m] | RMSE [m] | Bias [m] | Balance Score (F1) | Ähnlichkeitsmaß (IoU) | Fläche KI [$m^2$] | Fläche GRASS [$m^2$] | Vol KI [$m^3$] | Vol GRASS [$m^3$] |
| UG2_1_80 | CAL_QM | 0.010 | 0.003 | 0.022 | 0.000 | 0.284 | 0.165 | 180 220 | 180 226 | 8 074 | 7 823 |

# 4. Diskussion

Die Ergebnisse zeigen die zwei unterschiedlichen Leistungen der KI-Modellierung. Für das Untersuchungsgebiet 1, welches als urbanes Trainingsgebiet fungiert, erreicht das U-Net-ähnliche Modell eine brauchbare räumliche Übereinstimmung (F1, IoU) bei geringen mittleren Tiefenfehlern, während der Transfer auf das rurale Untersuchungsgebiet 2 (RAW) vor allem ein systematischer Fehler (Bias) zu massiven Überschätzungen von Fläche und Volumen der Überflutung führt (Kapitel 4). Damit wird ein zentrales praktisches Problem KI-basierter Surrogatmodelle sichtbar, denn selbst wenn ein Modell räumliche Muster grundsätzlich erfasst, können sich die Werteverteilungen zwischen Trainings- und Zielgebiet unterscheiden, wodurch die Prognosen ohne Anpassung nicht zuverlässig skalieren (GHAZI AL-RAWAS et al. 2025; JIANG et al. 2021). Dieses Problem wird auch in der Flood-Mapping-Literatur als zentrale Forschungslücke beschrieben (BENTIVOGLIO et al. 2022).

## 5.1 Nutzen der Kalibrierung

UG2 (RAW) macht deutlich, dass der Transferfehler nicht primär durch einzelne Ausreißer erklärbar ist, sondern durch die Verschiebung der Skala der Wassertiefen. Die QM-Kalibrierung korrigiert erfolgreich diese Skalierung und Verteilung der Wassertiefen (Bias), wodurch sich die Fläche und das Volumen stabilisiert (ANDRADE et al. 2024, Kapitel 4.3). Durch die Transformationsfunktion wird die Skala der KI-Ausgabe an die Referenzskala angepasst, ohne das KI-Modell erneut trainieren zu müssen (BENTIVOGLIO et al. 2022; SELEEM et al. 2023).

## 5.2 Grenzen der Kalibrierung und verbleibende Fehler

Gleichzeitig zeigt der Vergleich zwischen UG2 RAW und CAL die Grenze der rein skalaren Korrektur, denn räumliche Abweichungen in der genauen Lage der Wasserflächen werden nicht automatisch behoben. F1 und IoU zeigen, dass Kalibrierung allein nicht garantiert, dass die räumliche Lage der Wasserflächen besser getroffen wird. Quantile Mapping kann Werte „richtig skalieren“, aber es kann keine falsch vorhergesagten Wasserflächen an die richtige Position verschieben.

Diese verbleibenden Lagefehler sind im Transfer plausibel und können mehrere Ursachen haben. Unter anderem die heterogene Prozessdominanz zwischen urbanen und ruralen Gebieten durch die stärkere Bedeutung von Infiltration oder natürlichen Abflusskonzentrationen. Zudem die die verschiedene räumliche Beschaffenheit der Inputs der unterschiedlichen Parameter (BENTIVOGLIO et al. 2022).

## 5.3 Datenqualität und Realitätsbezug

Ein weiterer Punkt der Interpretation der Ergebnisse ist, dass die KI nicht gegen Messdaten evaluiert wird, sondern gegen den Output eines simplen physikalischen Modells. Die GRASS/SIMWE-Simulation ist damit eine konsistente Referenz, aber keine „Wahrheit“. Die KI lernt zwangsläufig die SIMWE-Logik und wird daher in erster Linie als Surrogat für SIMWE bewertet und nicht direkt als Realitätsmodell.

Das ist deshalb wichtig, weil SIMWE in dieser Arbeit bewusst als einfaches recheneffizientes physikalisches Modell eingesetzt wurde, mit Fokus auf Machbarkeit. Diese Vereinfachung ist methodisch sinnvoll, kann aber Prozesse nur näherungsweise abbilden. Damit kann auch der Referenzoutput systematische Abweichungen zur Realität enthalten, welchen die KI übernimmt.

Besonders relevant für den Realitätsbezug ist außerdem die Annahme konstanter Infiltrationsraten. Sowohl SIMWE als auch die KI wurden mit konstanten Infiltrationsparametern berechnet, da ein Fehler von Seitens GRASS GIS eingesehen wurde, der dazu führte, dass die Berechnung nicht funktionierte. Hydrologisch ist das stark idealisiert, da die Infiltration räumlich durch Boden, Landnutzungsart, Verdichtung und zeitlich durch Vorfeuchte, Sättigung, Ereignisverlauf variiert.

## 5.4 Zukunftsausblick

Aus den Ergebnissen ergibt sich als nächster Schritt für zukünftige Anpassungen des Modells dieser Arbeit, die erfolgreiche QM-kalibrierung durch räumlich explizite Korrekturen zu ergänzen. Ein Ansatz könnte die Residuen basierte Korrektur sein, also eine Machine-Learning-Vorhersage der Modellresiduen als Post-Processing-Schritt (LEE et al. 2025). Dabei lernt ein zweites Modell die systematischen Fehlmuster aus der Differenzkarte (Abb. 6, 7, 8, unten links) und nutzt topographische Indikatoren (Bsp. Über Height Above the Nearest Drainage (HAND)) um die räumliche Lage von Abflussbahnen und Senken besser zu erklären (LEE et al. 2025; RENNÓ et al. 2008).

Für Frühwarnsysteme ist es außerdem sinnvoll die Warnentscheidung über einen Trigger-Threshold zu definieren. Überschreitet die vorhergesagte Eintrittswahrscheinlichkeit einen bestimmten Wert, wird eine Warnung ausgelöst (ZHANG et al. 2024). Um Fehlalarme und verpasste Ereignisse zu reduzieren sollten Tresholds deshalb auf einer anwendungsbezogenen Sensitivitätsanalyse, bzw. der Auswertung mehrerer Schwellen beruhen und nicht auf einem einzelnen fixen Threshold (ZHANG et al. 2024).

# 5. Fazit

Für den Aufbau eines Geobasis-Zwillings zur Unterstützung von Einsatzprognosen für ressourcenbegrenzte Einsatzleitstellen in ganz Schleswig-Holstein ist ein gezielter, datenbasierter Ressourceneinsatz entscheidend. Den Rahmen zur Umsetzung der Prozessdigitalisierung und Automation setzt das Projekt Smart SH Emergency. Ziel dieser Arbeit war es, die Machbarkeit und Leistungsfähigkeit einer KI-basierten Überflutungsprognose „vor der Lage“ zu evaluieren.

Zu dem Zweck wurde ein U-Net-ähnliches Surrogatmodell trainiert, um aus vier räumlichen Eingabelayern (DEM, Niederschlag, Rauigkeit, Infiltration) eine Wassertiefenkarte vorherzusagen. Als Referenz diente eine simple physikalische Simulation aus GRASS GIS (SIMWE). Zudem wurde die Übertragbarkeit des KI-Modells geprüft, indem das Modell im urbanen UG1 (Lübeck) trainiert wurde und anschließend ohne erneutes Training auf das rurale UG2 (Barnitz) angewandt. Über Regressions- und Flächenmetriken wurde das KI-Modell evaluiert.

Im Trainingskontext (UG1) zeigt das Modell eine zuverlässige Annäherung an das Referenzmodell. Die mittlere Abweichung der Wassertiefe ist gering (MAE) und die räumliche Überlappung der Überflutungsfläche beider Modelle erreicht mittlere bis gute Werte (F1, IoU). Gleichzeitig wird sichtbar, dass das KI-Modell tendenziell glattere, weniger detailreiche Muster erzeugt als die SIMWE-Modellierung und Überflutungen flächiger ausdehnt, ohne das Gesamtvolumen stark abweichen zu lassen.

Der Transfer auf UG2 macht jedoch die zentrale Herausforderung deutlich: Nicht einzelne Ausreißer, sondern ein systematischer Fehler der Skalierung (Bias) dominiert bei Übertragung die Abweichungen. Dies führt zu stark erhöhten Wassertiefen und in der Folge zu massiven Überschätzungen der Überflutungsfläche und des Volumens. Um dies zu Verhindern wird das Modell Kalibriert (QM), um Bias, Fläche und Volumen an die Referenzskala anzupassen, ohne das System erneut trainieren zu müssen. Gleichzeitig bleibt jedoch die pixelgenaue räumliche Übereinstimmung weiterhin begrenzt, was zeigt, dass eine skalare Verteilung zwar „wie viel Überflutung“ skaliert, aber nicht automatisch das „wo“ verbessert.

Für die Interpretation ist zentral, dass die KI gegen eine physikalische Referenz (SIMWE) und nicht gegen Messdaten trainiert wird, wodurch diese Arbeit primär die Fähigkeit der KI evaluiert, SIMWE-Outputs reproduzieren und beschleunigen zu können. Der Realitätsbezug hängt entsprechend von der Qualität der physikalischen Modellierung ab. Insbesondere die Verwendung eines vergleichsweisen einfachen physikalischen Modells mit konstanten Infiltrationswerten ermöglicht zwar eine schnelle Datenerzeugung, begrenzt aber die Übertragbarkeit auf reale Ereignisse.

Insgesamt zeigt die Arbeit auf, dass ein U-Net-ähnliches CNN sich grundsätzlich als schneller, zuverlässiger Ansatz zur Wassertiefenprognose eignet. Die Kalibrierung des Modells ist aber ein unvermeidbarer Schritt, um die zentralen Schwächen des Transfers auf andere Untersuchungsgebiete auszubessern. Für zukünftige Arbeiten sind besonders realitätsnähere, dynamische Infiltrationsraten und gegebenenfalls komplexere physikalische Modellierungen zu beachten. Darüber hinaus muss die räumliche Fehlerkorrektur, beispielsweise über Residuenmodelle mit topographischen Parametern im Fokus stehen, um neben der Skala auch die räumliche Lage der Überfflutung robuster zu treffen und das KI-Modell für die Vorhersage detaillierter Orte nutzen zu können.

# Literaturverzeichnis


Aguilar Andrade, Freya Saima, Richard Arsenault, Annie Poulin, Magali Troin, und William Armstrong. „Application of weather post-processing methods for operational ensemble hydrological forecasting on multiple catchments in Canada“. *Journal of Hydrology* 642 (Oktober 2024): 131861. https://doi.org/10.1016/j.jhydrol.2024.131861.

Badrinarayanan, Vijay, Alex Kendall, und Roberto Cipolla. „SegNet: A Deep Convolutional Encoder-Decoder Architecture for Image Segmentation“. *IEEE Transactions on Pattern Analysis and Machine Intelligence* 39, Nr. 12 (2017): 2481–95. https://doi.org/10.1109/TPAMI.2016.2644615.

Bentivoglio, Roberto, Elvin Isufi, Sebastian Nicolaas Jonkman, und Riccardo Taormina. „Deep Learning Methods for Flood Mapping: A Review of Existing Applications and Future Research Directions“. *Hydrology and Earth System Sciences* 26, Nr. 16 (2022): 4345–78. https://doi.org/10.5194/hess-26-4345-2022.

Byun, Kyuhyun, und Alan Hamlet. „An improved empirical quantile mapping approach for bias correction of extreme values in climate model simulations“. *Environmental Research Letters* 20 (Dezember 2024). https://doi.org/10.1088/1748-9326/ad9b3d.

Conv2d — PyTorch 2.10 Documentation“. Zugegriffen 2. März 2026. https://docs.pytorch.org/docs/stable/generated/torch.nn.Conv2d.html.

Enayati, Maedeh, Omid Bozorg-Haddad, Javad Bazrafshan, Somayeh Hejabi, und Xuefeng Chu. „Bias correction capabilities of quantile mapping methods for rainfall and temperature variables“. *Journal of Water and Climate Change* 12, Nr. 2 (2020): 401–19. https://doi.org/10.2166/wcc.2020.261.

Ghazi Al-Rawas, Mohammad Reza Nikoo, Nasim Sadra and Farid Mousavi „Integrated Quantile Mapping and Spatial Clustering for Robust Bias Correction of Satellite Precipitation in Data-Sparse Regions“. Zugegriffen 4. März 2026. https://www.mdpi.com/2071-1050/17/18/8321.

Henonin, Justine, Beniamino Russo, Ole Mark, und Philippe Gourbesville. „Real-time urban flood forecasting and modelling – a state of the art“. *Journal of Hydroinformatics* 15, Nr. 3 (2013): 717–36. https://doi.org/10.2166/hydro.2013.132.

Hofierka, Jaroslav, und Monika Knutová. „Simulating Spatial Aspects of a Flash Flood Using the Monte Carlomethod and GRASS GIS: A Case Study of the Malá Svinka Basin(Slovakia)“. *Open Geosciences* 7, Nr. 1 (2015): 20150013. https://doi.org/10.1515/geo-2015-0013.

Hoffmann, Julian, Holger Schüttrumpf: floodGAN: Using Deep Adversarial Learning to Predict Pluvial Flooding in Real Time“. Zugegriffen 27. Februar 2026. https://www.mdpi.com/2073-4441/13/16/2255.

Intergovernmental Panel On Climate Change (Ipcc). *Climate Change 2021 – The Physical Science Basis: Working Group I Contribution to the Sixth Assessment Report of the Intergovernmental Panel on Climate Change*. 1. Aufl. Cambridge University Press, 2023. https://doi.org/10.1017/9781009157896.

Jiang, Peishi, Nis Meinert, Helga Jordão, u. a. „Digital Twin Earth -- Coasts: Developing a Fast and Physics-Informed Surrogate Model for Coastal Floods via Neural Operators“. arXiv.Org, 14. Oktober 2021. https://arxiv.org/abs/2110.07100v1.

Lee, Haneul, Seungmin Lee, Hoyong Lee, Narae Kang, und Soojun Kim. „A Residual Correction Approach for Improving Rainfall-Runoff Model Performance in Flood Early Warning Systems“. *Natural Hazards* 121, Nr. 18 (2025): 21459–82. https://doi.org/10.1007/s11069-025-07639-9.

Lfs-sh-de„Feuerwehrbedarfsplanung in Schleswig-Holstein“. Zugegriffen 28. Februar 2026. https://www.lfs-sh.de/BSBP/Gemeinde/GeoLage.php?ab=1.

Löwe, Roland, Julian Böhm, David Getreuer Jensen, Jorge Leandro, und Søren Højmark Rasmussen. „U-FLOOD – Topographic deep learning for predicting urban pluvial flood water depth“. *Journal of Hydrology* 603 (Dezember 2021): 126898. https://doi.org/10.1016/j.jhydrol.2021.126898.

Rennó, Camilo Daleles, Antonio Donato Nobre, Luz Adriana Cuartas, u. a. „HAND, a new terrain descriptor using SRTM-DEM: Mapping terra-firme rainforest environments in Amazonia“. *Remote Sensing of Environment* 112, Nr. 9 (2008): 3469–81. https://doi.org/10.1016/j.rse.2008.03.018.

Ronneberger, Olaf, Philipp Fischer, und Thomas Brox. „U-Net: Convolutional Networks for Biomedical Image Segmentation“. arXiv:1505.04597. Preprint, arXiv, 18. Mai 2015. https://doi.org/10.48550/arXiv.1505.04597.

schleswig-holstein.de. „Das Digitalisierungsprogramm für Schleswig-Holstein“. Zugegriffen 28. Februar 2026. https://www.schleswig-holstein.de/DE/fachinhalte/D/Digitalisierung/digitalisierungsprogramm.

Schumacher, Russ S. „Heavy Rainfall and Flash Flooding“. In *Oxford Research Encyclopedia of Natural Hazard Science*. 2017. https://doi.org/10.1093/acrefore/9780199389407.013.132.

Scikit-Learn. „F1_score“. Zugegriffen 3. März 2026. https://scikit-learn/stable/modules/generated/sklearn.metrics.f1_score.html.

Seleem, Omar, Georgy Ayzel, Axel Bronstert, und Maik Heistermann. „Transferability of Data-Driven Models to Predict Urban Pluvial Flood Water Depth in Berlin, Germany“. *Natural Hazards and Earth System Sciences* 23, Nr. 2 (2023): 809–22. https://doi.org/10.5194/nhess-23-809-2023.

TensorFlow. „Tf.Keras.Layers.Conv2D | TensorFlow v2.16.1“. Zugegriffen 2. März 2026. https://www.tensorflow.org/api_docs/python/tf/keras/layers/Conv2D.

V7labs.com:„Intersection over Union (IoU): Definition, Calculation, Code“. Zugegriffen 3. März 2026. https://www.v7labs.com/blog/intersection-over-union-guide.

Vrijling j.k., jonkmann: *Loss of Life Due to Floods*. o. J. Zugegriffen 28. Februar 2026. https://onlinelibrary.wiley.com/doi/10.1111/j.1753-318X.2008.00006.x.

Zhang, Ruikang, Dedi Liu, Lihua Xiong, Jie Chen, Hua Chen, und Jiabo Yin. „Determining the Threshold of Issuing Flash Flood Warnings Based on People’s Response Process Simulation“. *Hydrology and Earth System Sciences* 28, Nr. 23 (2024): 5229–47. https://doi.org/10.5194/hess-28-5229-2024.

**Erklärung zur Prüfungsfähigkeit und zum selbstständigen Erarbeiten**

Hiermit erkläre ich gemäß § 9 Abs. 6 PVO, dass ich prüfungsfähig bin, und gemäß § 9 Abs. 7 PVO, dass ich meine Arbeit selbstständig verfasst, keine anderen als die angegebenen Quellen und Hilfsmittel benutzt und meine Arbeit in keinem anderen Prüfungsverfahren eingereicht habe. Insbesondere die allgemein gültigen Zitierregeln für wissenschaftliches Arbeiten habe ich befolgt. Mit einer Überprüfung meiner Hausarbeit durch eine Plagiatssoftware bin ich einverstanden.

Kiel, 13.03.2026 .....
(Ort, Datum) (handschriftliche Unterschrift des Autor)